

Laboratório de Dinâmica dos Fluidos Computacional (LabFluid)

Solução de EDPs por Redes Neurais

Prof. Roberto Ribeiro Santos Júnior

Prof. Thiago de Oliveira Quinelato

Guilherme Furquim

Guilherme Ozanski

Larry Steffen Bertoncello

Lucas Xavier

Samuel Kutz Paranhos

Universidade Federal do Paraná

10 de março de 2025

Sumário

1. LabFluid
2. Equações Diferenciais Parciais (EDPs)
3. Redes Neurais
4. PINNs
5. Exemplos

LabFluid

Apresentação

Professores

Professores:

- ▶ Profa. Ailín Ruiz de Zarate Fabregas
- ▶ Prof. Elías Alfredo Gudiño Rojas
- ▶ Prof. Roberto Ribeiro Santos Jr.
- ▶ Prof. Thiago de Oliveira Quinelato



Equações Diferenciais Parciais (EDPs)

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- equações algébricas (soluções são números);
- relações de recorrência (soluções são sequências);
- equações diferenciais ordinárias/parciais (soluções são funções).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ equações diferenciais ordinárias/parciais (soluções são **funções**).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ equações diferenciais ordinárias/parciais (soluções são **funções**).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ **equações diferenciais ordinárias/parciais** (soluções são **funções**).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ **equações diferenciais ordinárias/parciais** (soluções são **funções**).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais

Introdução

No contexto de modelagem matemática, muitas vezes encontramos cenários onde modelamos um problema como a solução de equações.

Alguns tipos comuns de equações são:

- ▶ equações algébricas (soluções são números);
- ▶ relações de recorrência (soluções são sequências);
- ▶ **equações diferenciais ordinárias/parciais** (soluções são **funções**).

Usamos equações diferenciais quando estamos à procura de **funções** que satisfazem as equações do modelo. Tipicamente, essas equações vêm de leis físicas, químicas, biológicas, etc.

Equações Diferenciais Ordinárias (EDOs)

Exemplo de EDO

A solução de uma **Equação diferencial ordinária** é uma função de **uma variável** que satisfaz certas condições sobre suas derivadas, por exemplo:

⇒ Exemplo – Problema de Valor Inicial (PVI): Dado $\lambda \in \mathbb{R}$, encontrar a função $y: \mathbb{R} \rightarrow \mathbb{R}$ que satisfaz

$$\begin{cases} y'(t) = \lambda y(t) & \forall t \in \mathbb{R}, \\ y(0) = y_0, \end{cases}$$

⇒ Solução:

$$y(t) = y_0 e^{\lambda t} \quad (\text{uma função})$$

Equações Diferenciais Ordinárias (EDOs)

Exemplo de EDO

A solução de uma **Equação diferencial ordinária** é uma função de **uma variável** que satisfaz certas condições sobre suas derivadas, por exemplo:

- ▶ Exemplo – Problema de Valor Inicial (PVI): Dado $\lambda \in \mathbb{R}$, encontrar a função $y : \mathbb{R} \rightarrow \mathbb{R}$ que satisfaz

$$\begin{cases} \mathbf{y}'(t) = \lambda \mathbf{y}(t) & \forall t \in \mathbb{R}, \\ \mathbf{y}(0) = y_0, \end{cases}$$

- ▶ Solução:

$$\mathbf{y}(t) = y_0 e^{\lambda t} \quad (\text{uma função})$$

Equações Diferenciais Ordinárias (EDOs)

Exemplo de EDO

A solução de uma **Equação diferencial ordinária** é uma função de **uma variável** que satisfaz certas condições sobre suas derivadas, por exemplo:

- ▶ Exemplo – Problema de Valor Inicial (PVI): Dado $\lambda \in \mathbb{R}$, encontrar a função $y : \mathbb{R} \rightarrow \mathbb{R}$ que satisfaz

$$\begin{cases} \mathbf{y}'(t) = \lambda \mathbf{y}(t) & \forall t \in \mathbb{R}, \\ \mathbf{y}(0) = y_0, \end{cases}$$

- ▶ Solução:

$$\mathbf{y}(t) = y_0 e^{\lambda t} \quad (\text{uma função})$$

Equações Diferenciais Parciais (EDPs)

Exemplo de EDP

A solução de uma **Equação diferencial parcial** é uma função de **várias variáveis** que satisfaz condições sobre suas derivadas parciais. Mais especificamente, tome o seguinte exemplo:

➤ Exemplo – Equação do Calor: Dados $\alpha \in \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$, encontrar a função $u = u(x, t)$ que satisfaz

$$\begin{cases} u_t = \alpha u_{xx}, & (x, t) \in (-\pi, \pi) \times (0, 6), \\ u(x, 0) = f(x), & x \in (-\pi, \pi), \\ u(\pm\pi, t) = 0, & t \in (0, 6), \end{cases}$$

➤ Solução para $\alpha = 1$ e $f(x) = 3 \sin(x)$:

$$u(x, t) = 3e^{-t} \sin(x).$$

Equações Diferenciais Parciais (EDPs)

Exemplo de EDP

A solução de uma **Equação diferencial parcial** é uma função de **várias variáveis** que satisfaz condições sobre suas derivadas parciais. Mais especificamente, tome o seguinte exemplo:

- Exemplo – Equação do Calor: Dados $\alpha \in \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$, encontrar a função $u = u(x, t)$ que satisfaz

$$\begin{cases} u_t = \alpha u_{xx}, & (x, t) \in (-\pi, \pi) \times (0, 6), \\ u(x, 0) = f(x), & x \in (-\pi, \pi), \\ u(\pm\pi, t) = 0, & t \in (0, 6), \end{cases}$$

- Solução para $\alpha = 1$ e $f(x) = 3 \sin(x)$:

$$u(x, t) = 3e^{-t} \sin(x).$$

Equações Diferenciais Parciais (EDPs)

Exemplo de EDP

A solução de uma **Equação diferencial parcial** é uma função de **várias variáveis** que satisfaz condições sobre suas derivadas parciais. Mais especificamente, tome o seguinte exemplo:

- Exemplo – Equação do Calor: Dados $\alpha \in \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$, encontrar a função $u = u(x, t)$ que satisfaz

$$\begin{cases} u_t = \alpha u_{xx}, & (x, t) \in (-\pi, \pi) \times (0, 6), \\ u(x, 0) = f(x), & x \in (-\pi, \pi), \\ u(\pm\pi, t) = 0, & t \in (0, 6), \end{cases}$$

- Solução para $\alpha = 1$ e $f(x) = 3 \sin(x)$:

$$u(x, t) = 3e^{-t} \sin(x).$$

Redes Neurais

Redes Neurais

Estrutura




Figura: Ilustração de uma rede neural com 3 camadas (sendo 1 oculta).

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vieses de x e y ;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são matrizes de pesos;
- ▶ b_1 e b_2 são os vieses de cada camada;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

▶ W_1 e W_2 são as matrizes de pesos;

▶ b_1 e b_2 são os vetores de vieses;

▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de vieses;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de vieses;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de vieses;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Estrutura

Essencialmente, uma rede neural é uma **função parametrizada** $f(x; \theta)$:

- ▶ x representa os dados de entrada
- ▶ θ representa os parâmetros do modelo (pesos e vieses).
- ▶ Ajustamos θ para fazer f **aproximar** uma saída desejada específica para cada x .

Uma rede neural simples pode ser representada como:

$$f(x) = \sigma(W_2 \sigma(W_1 x + b_1) + b_2),$$

onde:

- ▶ W_1 e W_2 são as matrizes de pesos;
- ▶ b_1 e b_2 são os vetores de vieses;
- ▶ σ é uma função de ativação não-linear.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- Prover um banco de imagens rotuladas como entrada x ;
- A partir de uma configuração inicial de pesos e vieses (θ) a rede tomará uma decisão;
- Se a alteração para minimizar o erro na decisão;
- A rede toma outra decisão, e o processo repete-se.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses** (θ) a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses (θ)** a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses (θ)** a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses (θ)** a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.

Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses (θ)** a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo – MNIST

Considere uma rede neural que tenta identificar o número escrito numa imagem.


Roteiro:

- ▶ Prover um banco de imagens rotuladas como **entrada x** ;
- ▶ A partir de uma configuração inicial de **pesos e vieses (θ)** a rede tomará uma decisão;
- ▶ θ é alterado para minimizar o erro na decisão.
- ▶ A rede toma outra decisão, e o processo segue.

Uma vez treinada, a rede está pronta para reconhecer imagens novas para ela.

Redes Neurais

Exemplo



PINNs

PINNs

O que é?

- ▶ PINN¹ é um acrônimo para *Physics Informed Neural Network*, Rede Neural Informada por Física.
- ▶ É uma rede neural que usa informações da Física (expressas em equações diferenciais) para procurar uma solução numérica para uma EDP.
- ▶ Formalmente, considere o problema de encontrar uma função $u : \Omega \times [0, T] \rightarrow \mathbb{R}$ que satisfaz a equação diferencial parcial da forma

$$u_t + \mathcal{N}[u; \lambda] = 0,$$

acrescida de condições de contorno e iniciais, onde $\Omega \subset \mathbb{R}$ e $\mathcal{N}$ é um operador diferencial (possivelmente não-linear) parametrizado por λ .

- ▶ Exemplo: para escrever a equação do transporte, $u_t + au_x = 0$, tomamos $\mathcal{N}[u; a] = au_x$.

¹Maziar Raissi, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven solutions of nonlinear partial differential equations”. Em: *arXiv preprint arXiv:1711.10561*.

PINNs

O que é?

- ▶ PINN¹ é um acrônimo para *Physics Informed Neural Network*, Rede Neural Informada por Física.
- ▶ É uma rede neural que usa informações da Física (expressas em equações diferenciais) para procurar uma solução numérica para uma EDP.
- ▶ Formalmente, considere o problema de encontrar uma função $u : \Omega \times [0, T] \rightarrow \mathbb{R}$ que satisfaz a equação diferencial parcial da forma

$$u_t + \mathcal{N}[u; \lambda] = 0,$$

acrescida de condições de contorno e iniciais, onde $\Omega \subset \mathbb{R}$ e $\mathcal{N}$ é um operador diferencial (possivelmente não-linear) parametrizado por λ .

- ▶ Exemplo: para escrever a equação do transporte, $u_t + au_x = 0$, tomamos $\mathcal{N}[u; a] = au_x$.

¹Maziar Raissi, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven solutions of nonlinear partial differential equations”. Em: *arXiv preprint arXiv:1711.10561*.

PINNs

O que é?

- ▶ PINN¹ é um acrônimo para *Physics Informed Neural Network*, Rede Neural Informada por Física.
- ▶ É uma rede neural que usa informações da Física (expressas em equações diferenciais) para procurar uma solução numérica para uma EDP.
- ▶ Formalmente, considere o problema de encontrar uma função $u : \Omega \times [0, T] \rightarrow \mathbb{R}$ que satisfaz a equação diferencial parcial da forma

$$u_t + \mathcal{N}[u; \lambda] = 0,$$

acrescida de condições de contorno e iniciais, onde $\Omega \subset \mathbb{R}$ e $\mathcal{N}$ é um operador diferencial (possivelmente não-linear) parametrizado por λ .

- ▶ Exemplo: para escrever a equação do transporte, $u_t + au_x = 0$, tomamos $\mathcal{N}[u; a] = au_x$.

¹Maziar Raissi, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven solutions of nonlinear partial differential equations”. Em: *arXiv preprint arXiv:1711.10561*.

PINNs

O que é?

- ▶ PINN¹ é um acrônimo para *Physics Informed Neural Network*, Rede Neural Informada por Física.
- ▶ É uma rede neural que usa informações da Física (expressas em equações diferenciais) para procurar uma solução numérica para uma EDP.
- ▶ Formalmente, considere o problema de encontrar uma função $u : \Omega \times [0, T] \rightarrow \mathbb{R}$ que satisfaz a equação diferencial parcial da forma

$$u_t + \mathcal{N}[u; \lambda] = 0,$$

acrescida de condições de contorno e iniciais, onde $\Omega \subset \mathbb{R}$ e $\mathcal{N}$ é um operador diferencial (possivelmente não-linear) parametrizado por λ .

- ▶ Exemplo: para escrever a equação do transporte, $u_t + au_x = 0$, tomamos $\mathcal{N}[u; a] = au_x$.

¹Maziar Raissi, Paris Perdikaris e George Em Karniadakis (2017). “Physics Informed Deep Learning (Part I): Data-driven solutions of nonlinear partial differential equations”. Em: *arXiv preprint arXiv:1711.10561*.

O que difere uma PINN de outras redes neurais é a forma como a função do erro é definida.

Defina $D(x, t) := u_t(x, t) + \mathcal{N}[u(x, t); \lambda]$ (o lado esquerdo da equação diferencial calculado em um ponto (x, t) do domínio). Vamos resolver um problema da forma:

$$\begin{aligned} \min |D(x, t)|, & \quad (x, t) \in \Omega \times [0, T], \\ u(x, 0) = u_0(x), & \quad x \in \Omega, \\ u(x, t) = u_b(x, t), & \quad (x, t) \in \partial\Omega \times [0, T]. \end{aligned}$$

O que difere uma PINN de outras redes neurais é a forma como a função do erro é definida.

Defina $D(x, t) := u_t(x, t) + \mathcal{N}[u(x, t); \lambda]$ (o lado esquerdo da equação diferencial calculado em um ponto (x, t) do domínio). Vamos resolver um problema da forma:

$$\begin{aligned} \min |D(x, t)|, & \quad (x, t) \in \Omega \times [0, T], \\ u(x, 0) = u_0(x), & \quad x \in \Omega, \\ u(x, t) = u_b(x, t), & \quad (x, t) \in \partial\Omega \times [0, T]. \end{aligned}$$

O que difere uma PINN de outras redes neurais é a forma como a função do erro é definida.

Defina $D(x, t) := u_t(x, t) + \mathcal{N}[u(x, t); \lambda]$ (o lado esquerdo da equação diferencial calculado em um ponto (x, t) do domínio). Vamos resolver um problema da forma:

$$\begin{aligned} \min |D(x, t)|, & \quad (x, t) \in \Omega \times [0, T], \\ u(x, 0) = u_0(x), & \quad x \in \Omega, \\ u(x, t) = u_b(x, t), & \quad (x, t) \in \partial\Omega \times [0, T]. \end{aligned}$$

Uma PINN é capaz de aproximar $u(x, t)$ por minimizar a função de erro.

$$\text{EMQ} = \text{EMQ}_{\mathcal{D}} + \text{EMQ}_0 + \text{EMQ}_b,$$

onde

- ▶ $\text{EQM}_{\mathcal{D}} = \frac{1}{N_{\mathcal{D}}} \sum_{i=1}^{N_{\mathcal{D}}} |\mathcal{D}(x_i, t_i)|^2$, com (x_i, t_i) , $i = 1, \dots, N_{\mathcal{D}}$ pontos no domínio;
- ▶ $\text{EQM}_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |(u(x_i, 0) - u_0(x_i))|^2$, com $(x_i, 0)$, $i = 1, \dots, N_0$ pontos iniciais;
- ▶ $\text{EQM}_b = \frac{1}{N_b} \sum_{i=1}^{N_b} |u(x_i, t_i) - u_b(x_i, t_i)|^2$, com (x_i, t_i) , $i = 1, \dots, N_b$ pontos na borda.

Uma PINN é capaz de aproximar $u(x, t)$ por minimizar a função de erro.

$$\text{EMQ} = \text{EMQ}_{\mathcal{D}} + \text{EMQ}_0 + \text{EMQ}_b,$$

onde

- ▶ $\text{EQM}_{\mathcal{D}} = \frac{1}{N_{\mathcal{D}}} \sum_{i=1}^{N_{\mathcal{D}}} |\mathcal{D}(x_i, t_i)|^2$, com (x_i, t_i) , $i = 1, \dots, N_{\mathcal{D}}$ pontos no domínio;
- ▶ $\text{EQM}_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |(u(x_i, 0) - u_0(x_i))|^2$, com $(x_i, 0)$, $i = 1, \dots, N_0$ pontos iniciais;
- ▶ $\text{EQM}_b = \frac{1}{N_b} \sum_{i=1}^{N_b} |u(x_i, t_i) - u_b(x_i, t_i)|^2$, com (x_i, t_i) , $i = 1, \dots, N_b$ pontos na borda.

PINNs

DeepXDE

DeepXDE é uma biblioteca em Python para programar PINNs.




Figura: Lu Lu (Universidade de Yale), criador da DeepXDE.

Exemplos

Exemplos

Equação do Transporte – Guilherme Furquim

Exemplos

Equação do Transporte – Guilherme Furquim


Resolvemos via PINNs a equação do transporte para $a = 2$: $u_t + 2u_x = 0$.

Parâmetro	Valor
Domínio espacial (x)	$[-5, 15]$
Domínio temporal (t)	$[0, 7.5]$
Pontos no domínio ($N_{\mathcal{D}}$)	10 000
Pontos na condição inicial (N_0)	4 000
Pontos na borda (N_b)	4 000
Função de Ativação	tanh
Neurônios por camada	60
Camadas intermediárias	5
Iterações do otimizador	10 000
Taxa de Aprendizado	0.001

Exemplos

Equação do Transporte – Guilherme Furquim


10 iterações:



Exemplos

Equação do Transporte – Guilherme Furquim


100 iterações:



Exemplos

Equação do Transporte – Guilherme Furquim


500 iterações:



Exemplos

Equação do Transporte – Guilherme Furquim


1000 iterações:



Exemplos

Equação do Transporte – Guilherme Furquim

10000 iterações:



Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

Exemplos

Equação do Transporte com Velocidade Variável

Encontrar a função $u = u(x, t)$ que satisfaça o seguinte problema de valor inicial e de contorno:

$$\begin{cases} u_x + c(x)u_t = 0, & (x, t) \in (-9, 9) \times (0, 1), \\ u(x, 0) = f(x), & x \in (-9, 9), \\ u(\pm 9, t) = 0, & t \in (0, 2P), \end{cases}$$

onde $c(x) = 1/5 + \sin^2(x - 1)$ e $f(x) = e^{-100(x-1)^2}$.

Fisicamente, essa equação modela a dinâmica de uma onda, cujo perfil inicial é dado por $f(x)$ e que se propaga com velocidade $c(x)$ que varia conforme a posição no espaço.

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski




Figura: Solução analítica da Equação do Transporte com Velocidade Variável.

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

$$\left\{ \begin{array}{ll} u_x + c(x)u_t = 0, & (x, t) \in (-9, 9) \times (0, 1), \\ u(x, 0) = f(x), & x \in (-9, 9), \\ u(\pm 9, t) = 0, & t \in (0, 2P). \end{array} \right.$$



$$\begin{array}{ll} \text{Prob. 1:} & \min |u_t + c(x)u_x|, \quad (x, t) \in (-9, 9) \times (0, 1), \\ \text{Prob. 2:} & \min |u(x, 0) - f(x)|, \quad x \in (-9, 9), \\ \text{Prob. 3:} & \min |u(\pm 9, t)|, \quad t \in (0, 2P). \end{array}$$

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

$$\min_{W,b} EQM$$

$$EQM = EQM_{\mathcal{D}} + EQM_0 + EQM_b$$

$$EQM_{\mathcal{D}} = \frac{1}{N_{\mathcal{D}}} \sum_{i=1}^{N_{\mathcal{D}}} |\hat{u}_t(x_{\mathcal{D}}^i, t_{\mathcal{D}}^i) + c(x_{\mathcal{D}}^i) \hat{u}_x(x_{\mathcal{D}}^i, t_{\mathcal{D}}^i)|^2$$

$$EQM_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |\hat{u}(x_0^i, 0) - F(x_0^i)|^2$$

$$EQM_b = \frac{1}{N_b} \sum_{i=1}^{N_b} |\hat{u}(\pm \bar{x}, t_b^i)|^2$$

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

Arquitetura e Parâmetros da Rede Neural:

Parâmetro	Valor
Domínio espacial (x)	$[-9, 9]$
Domínio temporal (t)	$[0, 2P]$
Pontos no domínio ($N_{\mathcal{D}}$)	16 000
Pontos na fronteira (N_b)	400
Pontos na condição inicial (N_0)	1 000
Função de Ativação	tanh
Neurônios por camada	40
Camadas intermediárias	10
Iterações do otimizador	10 000

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

Domínio de Previsão: $(-9, 9) \times (0, 2P)$

Erro Relativo: 5.6×10^{-3}




Figura: Solução numérica e solução analítica.

Exemplos

Equação do Transporte com Velocidade Variável – Guilherme Ozanski

Domínio de Previsão: $(-12, 12) \times (0, 3P)$

Erro Relativo: 1.23




Figura: Solução numérica e solução analítica

Exemplos

Equação de Burgers Viscosa – Larry

Exemplos

Equação de Burgers Viscosa – Larry

Encontrar $u = u(x, t)$ que satisfaça

$$\begin{aligned}u_t + uu_x - \nu u_{xx} &= 0, & (x, t) &\in (-1, 1) \times (0, 1) \\u(x, 0) &= u_0(x), & x &\in (-1, 1), \\u(-1, t) = u(1, t) &= 0, & t &\in (0, 1),\end{aligned}$$

onde ν é a viscosidade.

No nosso estudo, consideramos $\nu = \frac{0.01}{\pi}$ e $u_0(x) = -\sin(\pi x)$.

Essa EDP foi inicialmente proposta como um modelo matemático para escoamento de fluido com turbulência.

Exemplos

Equação de Burgers Viscosa – Larry

Encontrar $u = u(x, t)$ que satisfaça

$$\begin{aligned}u_t + uu_x - \nu u_{xx} &= 0, & (x, t) &\in (-1, 1) \times (0, 1) \\u(x, 0) &= u_0(x), & x &\in (-1, 1), \\u(-1, t) = u(1, t) &= 0, & t &\in (0, 1),\end{aligned}$$

onde ν é a viscosidade.

No nosso estudo, consideramos $\nu = \frac{0.01}{\pi}$ e $u_0(x) = -\sin(\pi x)$.

Essa EDP foi inicialmente proposta como um modelo matemático para escoamento de fluido com turbulência.

Exemplos

Equação de Burgers Viscosa – Larry

Encontrar $u = u(x, t)$ que satisfaça

$$\begin{aligned}u_t + uu_x - \nu u_{xx} &= 0, & (x, t) &\in (-1, 1) \times (0, 1) \\u(x, 0) &= u_0(x), & x &\in (-1, 1), \\u(-1, t) = u(1, t) &= 0, & t &\in (0, 1),\end{aligned}$$

onde ν é a viscosidade.


No nosso estudo, consideramos $\nu = \frac{0.01}{\pi}$ e $u_0(x) = -\sin(\pi x)$.

Essa EDP foi inicialmente proposta como um modelo matemático para escoamento de fluido com turbulência.

Exemplos

Equação de Burgers Viscosa – Larry

N_D (Vermelho), N_0 (X Preto) e N_b (X Azul).



Exemplos

Equação de Burgers Viscosa – Larry




Figura: Oscilação do EMQ.




Figura: Não convergência do EMQ.

Figura: Efeitos da Taxa de Aprendizado.

Exemplos


Equação de Burgers Viscosa – Larry

Utilizando a técnica de PINNs com os seguintes parâmetros:

Parâmetro	Valor
Domínio espacial (x)	$[-1, 1]$
Domínio temporal (t)	$[0, 1]$
Pontos de colocação no domínio ($N_{\mathcal{D}}$)	10 000
Pontos de colocação na fronteira (N_b)	100
Pontos de colocação no valor inicial (N_0)	100
Função de Ativação	$\tanh$
Neurônios por camada	40
Camadas intermediárias	9
Iterações do otimizador	50 000

Exemplos

Equação de Burgers Viscosa – Larry



Exemplos

KdV e mKdV – Guilherme Furquim e Larry

Exemplos

KdV e mKdV – Guilherme Furquim e Larry

As equações de Korteweg-de-Vries (KdV) e Korteweg-de-Vries modificada (mKdV) modelam a evolução de uma onda não-linear unidimensional dispersiva e não-dissipativa ao longo do tempo. Essas equações podem ser escritas como:

$$\begin{aligned}u_t + u^p u_x + u_{xxx} &= 0, & x \in \mathbb{R}, t \in [0, \infty), \\u(x, 0) &= u_0(x, a), & x \in \mathbb{R},\end{aligned}$$

A única diferença entre as duas equações é a potência p da função u , sendo a KdV a equação com $p = 1$ e mKdV a equação com $p = 2$.

Exemplos

KdV e mKdV – Guilherme Furquim e Larry

As equações de Korteweg-de-Vries (KdV) e Korteweg-de-Vries modificada (mKdV) modelam a evolução de uma onda não-linear unidimensional dispersiva e não-dissipativa ao longo do tempo. Essas equações podem ser escritas como:

$$\begin{aligned}u_t + u^p u_x + u_{xxx} &= 0, & x \in \mathbb{R}, t \in [0, \infty), \\u(x, 0) &= u_0(x, a), & x \in \mathbb{R},\end{aligned}$$

A única diferença entre as duas equações é a potência p da função u , sendo a KdV a equação com $p = 1$ e mKdV a equação com $p = 2$.

Exemplos

KdV e mKdV – Guilherme Furquim e Larry

As soluções exatas das equações são:

$$u(x, t) = \begin{cases} a \operatorname{sech}^2(k(x - ct)), & k = \sqrt{a/12}, c = a/3, \quad \text{se } p = 1, \\ a \operatorname{sech}(k(x - ct)), & k = a/\sqrt{6}, c = a^2/6, \quad \text{se } p = 2. \end{cases}$$

Exemplos


KdV e mKdV – Guilherme Furquim e Larry

Resolvemos a equação de Korteweg-de-Vries modificada com *amplitude de onda variando* de 1 a 2, nos seguintes parâmetros.

Parâmetro	Valor
Domínio espacial (x)	$[-10, 10]$
Domínio temporal (t)	$[0, 15]$
Pontos no domínio ($N_{\mathcal{D}}$)	10 000
Pontos na fronteira (N_b)	4 000
Pontos na condição inicial (N_0)	4 000
Função de Ativação	tanh
Neurônios por camada	60
Camadas intermediárias	5
Iterações do otimizador	100 000

Exemplos

KdV e mKdV – Guilherme Furquim e Larry



Exemplos

KdV e mKdV – Guilherme Furquim e Larry





Figura: Erro Relativo L2 ao longo do tempo com amplitude variável.

Exemplos

KdV e mKdV – Guilherme Furquim e Larry



Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Encontrar a função $u = u(x, t)$ que satisfaça:

$$\begin{aligned}u_t + u_x + uu_x - u_{xxt} &= 0, & (x, t) &\in (-10, 20) \times (0, 4), \\u(x, 0) &= u_0(x), & x &\in (-10, 20), \\u(-10, t) &= g_1(t), & t &\in (0, 4), \\u(20, t) &= g_2(t), & t &\in (0, 4),\end{aligned}$$

onde

► u_0 é a **condição inicial** em $t = 0$;

► g_1, g_2 são **condições de contorno** que nos dizem como u atua na fronteira de x .

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Encontrar a função $u = u(x, t)$ que satisfaça:

$$\begin{aligned}u_t + u_x + uu_x - u_{xxt} &= 0, & (x, t) &\in (-10, 20) \times (0, 4), \\u(x, 0) &= u_0(x), & x &\in (-10, 20), \\u(-10, t) &= g_1(t), & t &\in (0, 4), \\u(20, t) &= g_2(t), & t &\in (0, 4),\end{aligned}$$

onde

- ▶ u_0 é a **condição inicial** em $t = 0$;
- ▶ g_1, g_2 são **condições de contorno** que nos dizem como u atua na fronteira de x .

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

A BBM é utilizada como uma alternativa ao modelo de KdV e possui solução viajante da forma:

$$u(x, t) = A \operatorname{sech}^2(k(x - ct)),$$

onde

- ▶ $A > 0$ é dado e chamado de **amplitude**;
- ▶ $k = \sqrt{\frac{A}{12 + 4A}}$, chamado de **frequência**;
- ▶ $c = 1 + \frac{A}{3}$, chamado de **velocidade**.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

A BBM é utilizada como uma alternativa ao modelo de KdV e possui solução viajante da forma:

$$u(x, t) = A \operatorname{sech}^2(k(x - ct)),$$

onde

- ▶ $A > 0$ é dado e chamado de **amplitude**;
- ▶ $k = \sqrt{\frac{A}{12 + 4A}}$, chamado de **frequência**;
- ▶ $c = 1 + \frac{A}{3}$, chamado de **velocidade**.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

A BBM é utilizada como uma alternativa ao modelo de KdV e possui solução viajante da forma:

$$u(x, t) = A \operatorname{sech}^2(k(x - ct)),$$

onde

- ▶ $A > 0$ é dado e chamado de **amplitude**;
- ▶ $k = \sqrt{\frac{A}{12 + 4A}}$, chamado de **frequência**;
- ▶ $c = 1 + \frac{A}{3}$, chamado de **velocidade**.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Substituindo na própria equação da BBM anterior, obtemos o nosso problema:

$$\begin{aligned}u_t + u_x + uu_x - u_{xxt} &= 0, & (x, t) &\in (-10, 20) \times (0, 4), \\u(x, 0) &= A \operatorname{sech}^2(kx), & x &\in (-10, 20), \\u(-10, t) &= A \operatorname{sech}^2(k(-10 - ct)), & t &\in (0, 4), \\u(20, t) &= A \operatorname{sech}^2(k(20 - ct)), & t &\in (0, 4),\end{aligned}$$

onde $A > 0$, $k = \sqrt{\frac{A}{12 + 4A}}$ e $c = 1 + \frac{A}{3}$.

Exemplos


Benjamin-Bona-Mahony (BBM) – Samuel

Utilizando a técnica de PINNs com os seguintes parâmetros:

Parâmetro	Valor
Amplitude inicial (A)	5
Domínio espacial (x)	$[-10, 20]$
Domínio temporal (t)	$[0, 4]$
Pontos no domínio (N_f)	15 000
Pontos na fronteira (N_b)	100
Pontos na condição inicial (N_0)	100
Neurônios por camada	50
Camadas intermediárias	3
Iterações do otimizador	15 000
Função de ativação	tanh

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel



Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Utilizamos o otimizador conhecido como ADAM (Adaptive Moment Estimation), que não é o único disponível pelo DeepXDE.


Assim, decidimos testar os seguintes otimizadores:

- ▶ **ADAM** (Adaptive Moment Estimation)
- ▶ **NADAM** (ADAM com *Nesterov Momentum*)
- ▶ **SGD** (Stochastic Gradient Descent)
- ▶ **L-BFGS** (Limited memory *Broyden-Fletcher-Goldfarb-Shanno*)


Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Épocas vs EQM (Log)



Tempo vs Erro Relativo



Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Conclusões dos experimentos PINNs para BBM:

- ▶ Pouca dificuldade para chegar em aproximações satisfatórias em relação às outras equações;
- ▶ Diferente de outras equações, o **L-BFGS** foi o otimizador campeão;
- ▶ Dentro do domínio temporal escolhido, a PINN tem erro satisfatório;
- ▶ Possibilidade de existir uma conexão entre otimizadores de PINNs e a EDP escolhida.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Conclusões dos experimentos PINNs para BBM:

- ▶ Pouca dificuldade para chegar em aproximações satisfatórias em relação às outras equações;
- ▶ Diferente de outras equações, o **L-BFGS** foi o otimizador campeão;
- ▶ Dentro do domínio temporal escolhido, a PINN tem erro satisfatório;
- ▶ Possibilidade de existir uma conexão entre otimizadores de PINNs e a EDP escolhida.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Conclusões dos experimentos PINNs para BBM:

- ▶ Pouca dificuldade para chegar em aproximações satisfatórias em relação às outras equações;
- ▶ Diferente de outras equações, o **L-BFGS** foi o otimizador campeão;
- ▶ Dentro do domínio temporal escolhido, a PINN tem erro satisfatório;
- ▶ Possibilidade de existir uma conexão entre otimizadores de PINNs e a EDP escolhida.

Exemplos

Benjamin-Bona-Mahony (BBM) – Samuel

Conclusões dos experimentos PINNs para BBM:

- ▶ Pouca dificuldade para chegar em aproximações satisfatórias em relação às outras equações;
- ▶ Diferente de outras equações, o **L-BFGS** foi o otimizador campeão;
- ▶ Dentro do domínio temporal escolhido, a PINN tem erro satisfatório;
- ▶ Possibilidade de existir uma conexão entre otimizadores de PINNs e a EDP escolhida.

Exemplos

Sine-Gordon – Lucas

Sine-Gordon – Lucas

Introdução

Equação de Sine-Gordon: A equação de Sine-Gordon é expressa por:

$$\begin{aligned}u_{tt} - u_{xx} + \sin(u) &= 0 & (x, t) &\in (-10, 10) \times (0, 15), \\u(x, 0) &= f(x) & x &\in (-10, 10),\end{aligned}$$

onde $f(x) = 4 \arctan\left(\exp\left(\frac{x}{\sqrt{1-a^2}}\right)\right)$ e a representa a velocidade de propagação da onda ao longo do eixo x .

Sine-Gordon – Lucas

Estruturação

Diferente dos outros trabalhos, foram utilizados **algoritmos evolucionários** para otimizar a escolha de hiperparâmetros do modelo:

- ▶ função de ativação;
- ▶ arquitetura da rede;
- ▶ balanço entre a contribuição do erro nas condições de contorno e do erro no domínio.

Sine-Gordon – Lucas

Estruturação

Diferente dos outros trabalhos, foram utilizados **algoritmos evolucionários** para otimizar a escolha de hiperparâmetros do modelo:

- ▶ função de ativação;
- ▶ arquitetura da rede;
- ▶ balanço entre a contribuição do erro nas condições de contorno e do erro no domínio.

Sine-Gordon – Lucas

Estruturação

Diferente dos outros trabalhos, foram utilizados **algoritmos evolucionários** para otimizar a escolha de hiperparâmetros do modelo:

- ▶ função de ativação;
- ▶ arquitetura da rede;
- ▶ balanço entre a contribuição do erro nas condições de contorno e do erro no domínio.

Sine-Gordon – Lucas

Parâmetros e Resultados

Parâmetro	Valor
Amplitude inicial (a)	0.9
Domínio espacial (x)	$[-10, 10]$
Domínio temporal (t)	$[0, 15]$
Pontos no domínio (N_f)	5 000
Pontos na fronteira (N_b)	10 000
Pontos na condição inicial (N_0)	10 000
Iterações do otimizador	100
Neurônios por camada (escolha da rede)	33
Camadas intermediárias(escolha da rede)	3
Função de Ativação (escolha da rede)	tanh
População por geração	20
Número de gerações	5

Melhor Função de Perda: 4.8e-08.

Obrigado!

Thiago Quinelato
thiago.quinelato@ufpr.br