Métodos de Aprendizado de Máquina Científico para o Sistema Não Linear de Equações de Boussinesq

Samuel Kutz Paranhos[1] Roberto Ribeiro Santos Junior[2]

[1]Bacharelado em Matemática Industrial, Universidade Federal do Paraná (UFPR), Curitiba, PR

[2]Departamento de Matemática, Universidade Federal do Paraná (UFPR), Curitiba, PR

Introdução

O sistema de Boussinesq é um sistema de equações diferenciais parciais (EDPs) não lineares e dispersivas que modela a propagação de ondas longas em águas rasas, em termos da elevação da superfície livre $\eta(x,t)$ e da velocidade horizontal média $u(x,t)$ [4]:

$$\begin{cases} \eta_t + u_x + \alpha\,(\eta u)_x = 0, & (x,t) \in [-60,60] \times [0,30], \\ u_t - \frac{\beta}{3}\,u_{xxt} + \eta_x + \alpha\,u u_x = 0, \\ \eta(x,0) = \operatorname{sech}^2(x), \quad u(x,0) = 0, \end{cases}$$

com condições de contorno periódicas em x. O coeficiente α controla a não linearidade e β a dispersão. Tomamos $\alpha = \beta$.

O sistema já foi bastante estudado por métodos clássicos, como o método pseudoespectral, mas, até onde sabemos, não por métodos de Aprendizado de Máquina Científico (*Scientific Machine Learning*, SciML) [1]. Este trabalho compara seis métodos de SciML com uma solução de referência pseudoespectral e investiga neles o viés espectral, a tendência de redes treinadas por gradiente aprenderem as baixas frequências antes das altas [5].

Metodologia

Como solução de referência para o Sistema de Boussinesq, utilizamos o pseudoespectral com Runge–Kutta de quarta ordem, gerando tanto os dados de treinamento quanto a referência. Os operadores aprendem com 20 parâmetros-exemplo, com $\alpha = \beta$ igualmente espaçados em $[0{,}1;\ 4{,}0]$, numa grade 128×128; as redes neurais aprendem apenas $\alpha = \beta = 3{,}21$. Todos os métodos usam o mesmo orçamento, 15.000 iterações do otimizador Adam. A acurácia é medida pelo erro relativo L^2 em cada instante denotado por $E(t_n)$. Para observar o viés espectral, medimos a média do erro espectral absoluto em três bandas de frequência (baixa, média e alta), denotada por E_{band}.

Métodos

Estudamos e implementamos seis métodos, divididos em duas classes:

Redes neurais

O *Multilayer Perceptron* (MLP) recebe as coordenadas (x,t) e devolve a solução nesse ponto. A *Physics-Informed Neural Network* (PINN) [6] usa a mesma rede e calcula o resíduo do sistema por diferenciação automática.

Operadores neurais

O *Fourier Neural Operator* (FNO) [2] aproxima o operador solução $(\alpha,\beta) \mapsto (\eta,u)$ com camadas que fazem convolução no espaço de Fourier, retendo apenas os modos mais baixos. O *Physics-Informed Neural Operator* (PINO) [3] usa o mesmo FNO e calcula o resíduo com derivadas espectrais em x e diferenças finitas em t. Uma vez treinado, um operador responde a um novo parâmetro com uma única passagem pela rede.

Composição da função de perda

Cada método minimiza uma soma ponderada de erros quadráticos médios; o regime de treinamento decide quais termos entram e completa o nome do método, como em PINO (*data and physics*):

$$\mathcal{L} = \lambda_{\text{data}}\,\mathcal{L}_{\text{data}} + \lambda_{\text{physics}}\,\mathcal{L}_{\text{physics}} + \lambda_{\text{ic}}\,\mathcal{L}_{\text{ic}}.$$

Regime	$\mathcal{L}_{\text{data}}$	$\mathcal{L}_{\text{physics}}$	$\mathcal{L}_{\text{ic}}$	Rede neural	Operador neural
Pure data	✓			MLP	FNO
Data and physics	✓	✓	✓	PINN	PINO
Pure physics		✓	✓	PINN	PINO

Resultados

PINO (data and physics)

O PINO (*data and physics*) teve a menor mediana do erro relativo entre os seis métodos em $\alpha = \beta = 3{,}21$ e resolução 256, e entre os operadores nos três valores do parâmetro testados. A Figura 1 mostra a sua previsão em $\alpha = \beta = 3{,}21$ e resolução 256, o dobro da de treinamento: a superfície prevista reproduz os dois pulsos que se afastam da origem e as oscilações dispersivas que os seguem, e o erro relativo à referência cresce ao longo da janela de tempo.

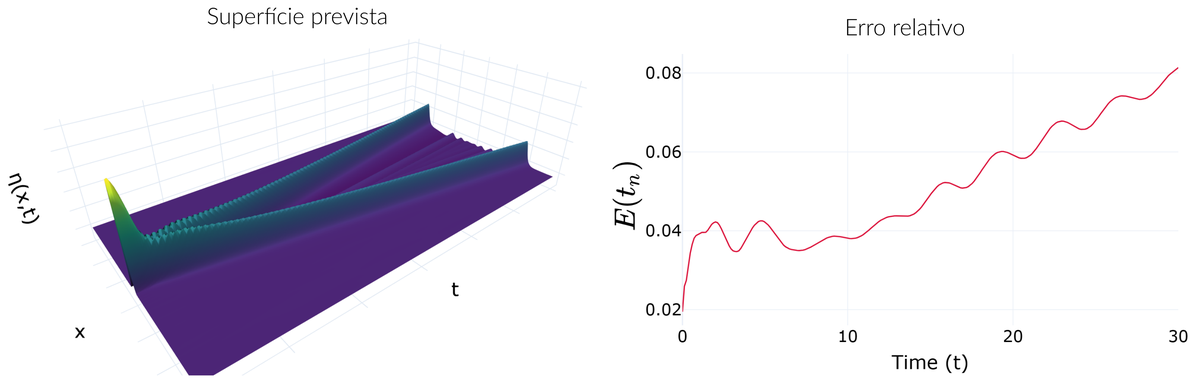


Figura 1. PINO (*data and physics*) em $\alpha = \beta = 3{,}21$ e resolução 256: elevação $\eta(x,t)$ prevista (esquerda) e erro relativo $E(t_n)$ em relação à referência pseudoespectral ao longo do tempo (direita).

Viés espectral na previsão

O viés espectral também aparece no resultado final do PINO (*data and physics*). No espectro da previsão (Figura 2), os modos baixos coincidem com os da referência, enquanto nos modos altos a amplitude prevista fica abaixo da amplitude de referência.

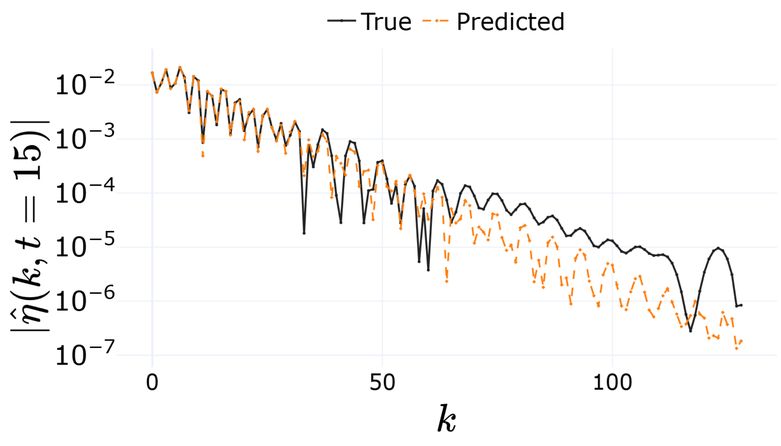


Figura 2. Espectro de η em $t = 15$ para o PINO (*data and physics*), em $\alpha = \beta = 3{,}21$ e resolução 256: amplitude $|\hat{\eta}(k,t)|$ da referência (*True*) e da previsão (*Predicted*).

Viés espectral no treinamento

A Figura 3 acompanha o erro por banda durante o treinamento dos três operadores, na amostra de treino mais próxima de $3{,}21$ ($\alpha = \beta \approx 3{,}18$) e na resolução de treinamento, 128. Nos dois PINOs, o erro da banda baixa cai continuamente, o da banda média cai mais devagar e o da banda alta fica quase constante após as primeiras iterações. No FNO (*pure data*), a banda baixa oscila durante todo o treinamento e a alta termina acima das outras duas. O PINO (*pure physics*) termina com erro maior nas três bandas do que o PINO (*data and physics*).

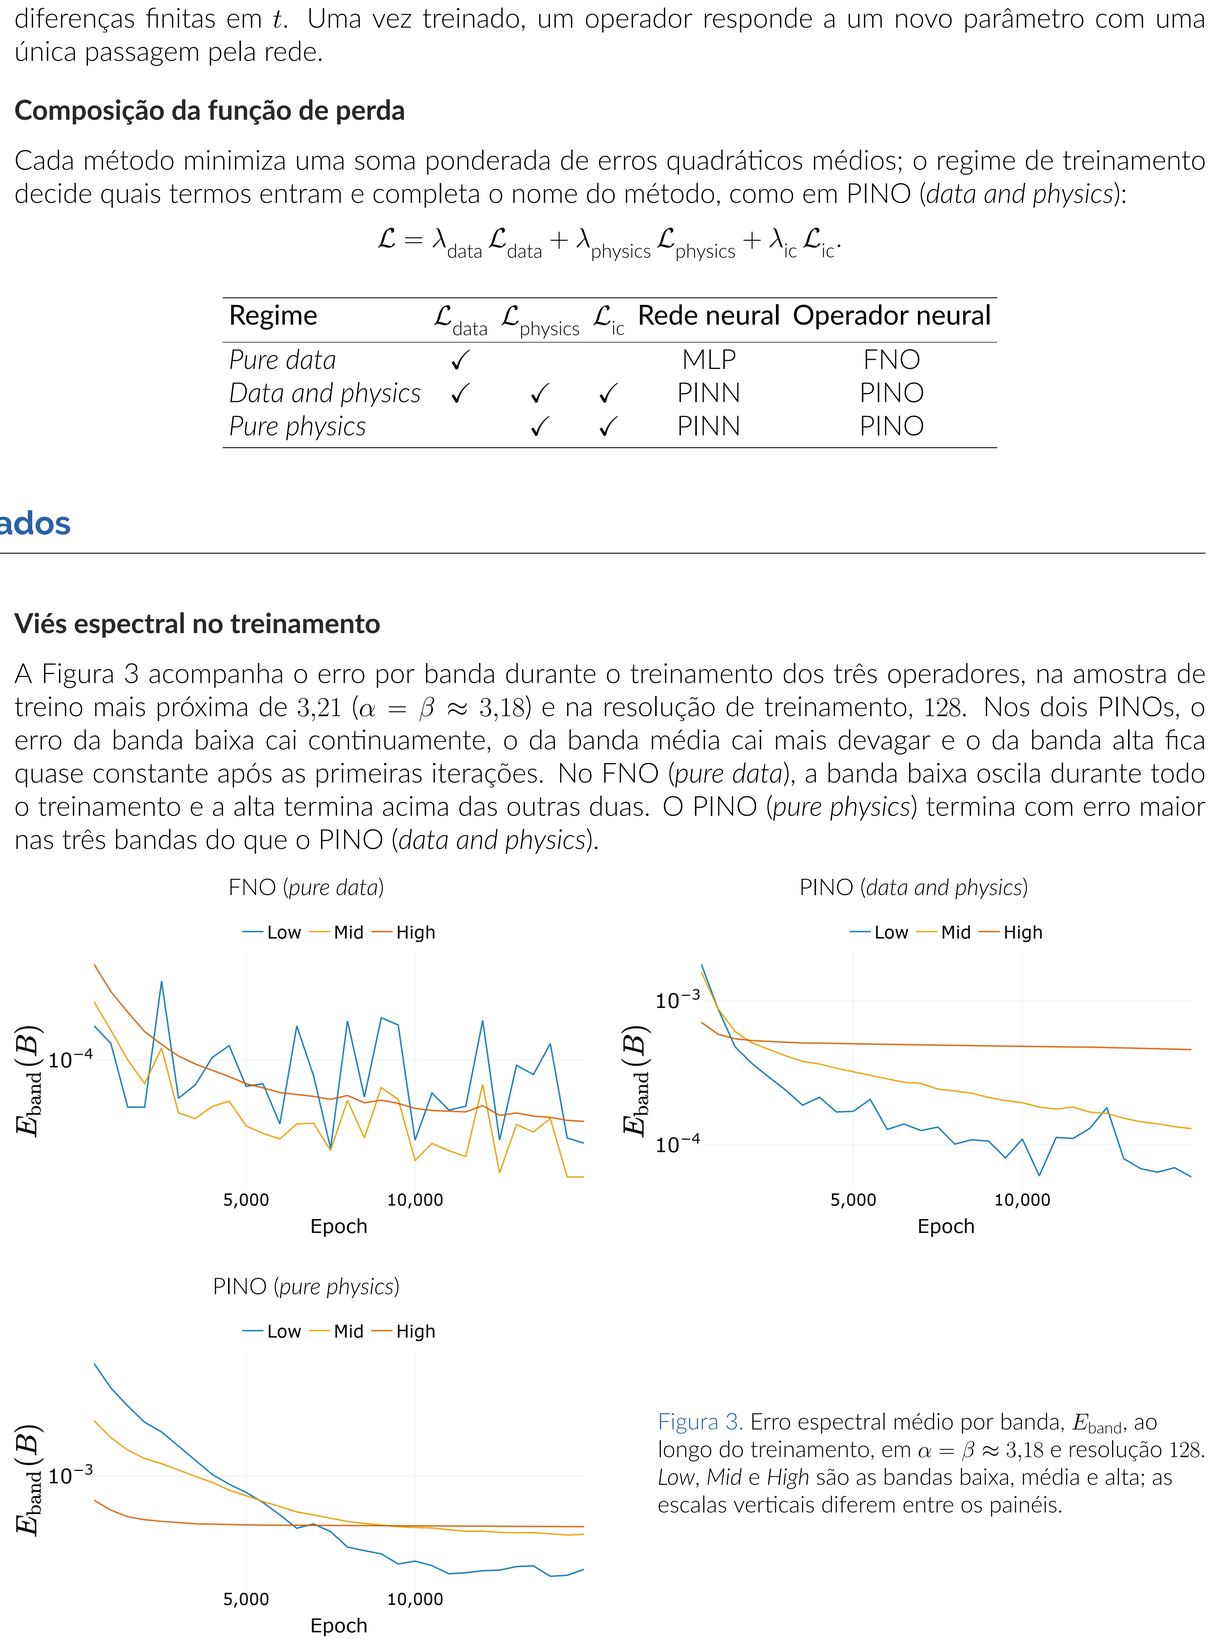


Figura 3. Erro espectral médio por banda, E_{band}, ao longo do treinamento, em $\alpha = \beta \approx 3{,}18$ e resolução 128. *Low*, *Mid* e *High* são as bandas baixa, média e alta; as escalas verticais diferem entre os painéis.

Conclusões

- O viés espectral apareceu nos três operadores neurais: ao fim do treinamento, a banda alta concentrou o maior erro, e nos dois PINOs ela quase não mudou após as primeiras iterações.
- Com dados supervisionados, os operadores terminaram o treinamento com erro menor nas bandas baixa e média do que apenas com o resíduo da equação.
- A combinação de dados e física teve o menor erro relativo entre os métodos testados: o resíduo funcionou melhor como regularizador somado aos dados do que como substituto deles.

Esses métodos complementam o solucionador clássico, sem substituí-lo. Um operador treinado responde a uma varredura de parâmetros com uma passagem pela rede, mas é o solucionador pseudoespectral que fornece os dados de treinamento e a referência contra a qual eles são medidos.

Referências

[1] Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S. e Yang, L. Physics-informed machine learning, *Nature Reviews Physics*, 3:422–440, 2021. DOI: 10.1038/s42254-021-00314-5.

[2] Li, Z., Kovachki, N., Azizzadenesheli, K., Liu, B., Bhattacharya, K., Stuart, A. e Anandkumar, A. Fourier neural operator for parametric partial differential equations, *International Conference on Learning Representations (ICLR)*, 2021.

[3] Li, Z., Zheng, H., Kovachki, N., Jin, D., Chen, H., Liu, B., Azizzadenesheli, K. e Anandkumar, A. Physics-informed neural operator for learning partial differential equations, *ACM/IMS Journal of Data Science*, 1(3):1–27, 2024. DOI: 10.1145/3648506.

[4] Martins, L. G. Estudo numérico do modelo Boussinesq com topografia e pressão variável no espaço e no tempo, Dissertação de Mestrado, UFPR, 2023.

[5] Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F. A., Bengio, Y. e Courville, A. On the spectral bias of neural networks, *Proceedings of the 36th International Conference on Machine Learning*, PMLR 97:5301–5310, 2019.

[6] Raissi, M., Perdikaris, P. e Karniadakis, G. E. Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations, *Journal of Computational Physics*, 378:686–707, 2019. DOI: 10.1016/j.jcp.2018.10.045.

samuelkutzparanhos1@gmail.com • Código: github.com/samuelkutz/TCC • Apoio: CNPq e LabFluid/UFPR